Міністерство освіти і науки України
Кам’янець-Подільський національний університет імені Івана
Огієнка Фізико-математичний факультет
Кафедра комп'ютерних наук

ЗВІТ З ПРОЄКТУ

з дисципліни «Аналіз великих наборів даних»

Тема: «**Прогнозування затримок вильоту внутрішніх авіарейсів у США**»

Виконав: здобувач вищої
освіти освітнього ступеня
«магістр» групи KN1-M26
спеціальності 122 Комп'ютерні науки
Вальцер Вадим Олександрович
Ел. пошта: kn1b22.valtser@kpnu.edu.ua

Посилання на репозиторій:
https://github.com/VadimValcerKN1B22/flight-delay-analysis

Кам’янець-Подільський – 2026

1. Вступ

Пунктуальність авіаперевезень є одним із критичних факторів стабільності транспортної інфраструктури, ефективності логістики та задоволеності пасажирів. Затримки рейсів щороку завдають мільярдних збитків авіаційній галузі через штрафні компенсації, понаднормові виплати персоналу, простої суден та перебудову логістичних ланцюгів стикувальних рейсів.

Питання дослідження: Чи можна передбачити затримку вильоту внутрішнього рейсу понад 15 хвилин за даними про авіакомпанію, аеропорт відправлення, запланований час вильоту та дистанцію польоту?

Кому корисна відповідь:

1. Авіакомпаніям та службам управління аеропортами – для завчасного коригування графіка польотів, динамічного планування завантаження терміналів і виходів на посадку, а також мінімізації ланцюгових затримок рейсів стикування.
2. Пасажирам та агрегаторам бронювання – для оцінки ризику зриву пересадок та прийняття рішень щодо оформлення страхових полісів або вибору менш ризикових рейсів.

2. Дані

Джерело даних: Відкритий набір «2015 Flight Delays and Cancellations» (Bureau of Transportation Statistics, U.S. Department of Transportation), опублікований на платформі Kaggle під ліцензією CC0: Public Domain.

Обсяг: Вихідний файл flights.csv містить 5 819 079 рядків та 31 стовпець загальним розміром 564.96 МБ на диску.

Очищення та підготовка даних:

1. Фільтрація: З аналізу вилучено скасовані (CANCELLED == 1) та перенаправленні (DIVERTED == 1) рейси, оскільки для них факт виконання польоту за розкладом відсутній. Також видалено записи з пропусками в полі DEPARTURE_DELAY (86 153 рядки, які належали саме скасованим рейсам).
2. Підсумковий обсяг: Після фільтрації набір даних налічує 5 714 008 рядків (збережено

понад 98.2% спостережень).

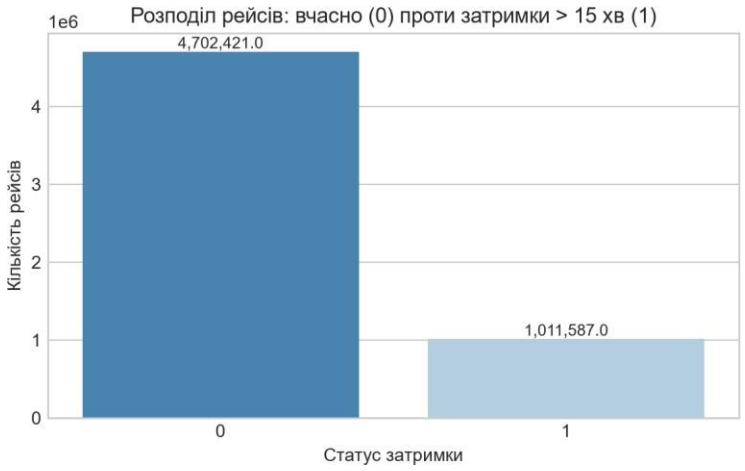
3. Цільова змінна: Сформовано бінарну мітку is_delayed: 1 – якщо затримка вильоту DEPARTURE_DELAY > 15 хвилин (за стандартом FAA затримки до 15 хв вважаються пунктуальними), 0 – в іншому випадку.
4. Генерація ознак: Зі стовпця SCHEDULED_DEPARTURE (формат hhmm) виділено окрему ознаку dep_hour (година доби від 0 до 23).

Опис використаних змінних:

Назва змінної	Тип	Опис ролі у дослідженні
AIRLINE	Категорія	Код перевізника (14 провідних авіакомпаній США)
ORIGIN_AIRPORT	Категорія	Код аеропорту відправлення (322 летовища)
DESTINATION_AIRPORT	Категорія	Код аеропорту прибуття
MONTH	Число (int8)	Місяць здійснення польоту (1–12)
DAY_OF_WEEK	Число (int8)	День тижня (1–7)
dep_hour	Число (int8)	Запланована година вильоту рейсу (0–23)
DISTANCE	Число (int16)	Відстань між аеропортами у милях
is_delayed	Бінарна (int8)	Цільова змінна (1 – затримка > 15 хв, 0 – вчасно)

Головні виявлені закономірності (EDA):

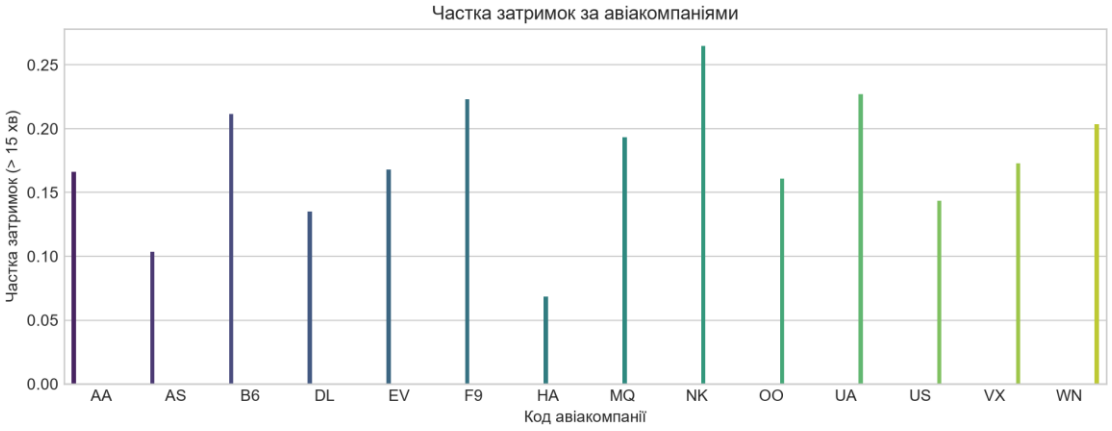
- Дисбаланс класів: 4 702 421 рейс (82.3%) вилетів вчасно, а 1 011 587 рейсів (17.7%) зазнали суттєвої затримки (файл target_distribution.png).



- Годинний тренд: Імовірність затримки демонструє виражену динаміку протягом доби. Найнижчий рівень спостерігається рано-вранці (5:00-6:00 ранку – менше 6%), після чого ризик монотонно зростає через накопичення ланцюгових затримок і сягає максимуму 27.8% у вечірній час пік (18:00-20:00) (файл delay_by_hour.png).



- Авіаперевізники: Різниця в пунктуальності між перевізниками сягає понад двократного розриву (від ~10% у найбільш надійних перевізників до понад 23% у бюджетних і чартерних лініях) (файл delay_by_airline.png).



3. Інструменти та обробка великих даних

Обробка повного набору з понад 5.7 млн записів вимагала застосування спеціальних методів оптимізації пам'яті та формату зберігання.

Застосовані прийоми для оптимізації:

1. Вибіркове читання колонок: Завантажувалися лише 10 необхідних атрибутів замість 31, що запобігло надмірному використанню оперативної пам'яті на старті.

2. Даункастинг числових типів (Downcasting): Стандартні 64-бітні типи було оптимізовано до int8 (для місяців, днів, годин та таргета) та int16 (для дистанції та затримки), а текстові поля переведено в категоріальний тип category.
3. Колоночний формат Parquet: Набір збережено у форматі Apache Parquet зі стисненням Snappy, що зменшило дисковий простір у 18 разів і кардинально прискорило зчитування.
4. Використання Polars: Для високошвидкісного зчитування та маніпуляції великими даними було використано мультипотоковий рушій Polars (на базі Rust/Apache Arrow).

Таблиця вимірювання часу та обсягів операцій:

Операція / Формат	Інструмент	Результат вимірювання
Читання вихідного flights.csv	Pandas (read_csv)	16.20 с
Збереження у Parquet	Pandas (to_parquet)	1.43 с
Читання flights_clean.parquet	Pandas (read_parquet)	0.55 с
Читання flights_clean.parquet	Polars (read_parquet)	0.23 с
Обсяг файлу на диску (CSV)	Файлова система	564.96 МБ
Обсяг файлу на диску (Parquet)	Файлова система	30.91 МБ (стиснення у 18.3 рази)

4. Моделі та перевірка результату Стратегія перевірки (Validation Strategy):

Для валідації застосовано стратифіковане розбиття вибірки на навчальну та тестову частини у пропорції 80% (Train: 4 571 206 спостережень) до 20% (Test: 1 142 802 спостереження) з фіксацією випадкового стану random_state=42. Перевірка здійснювалася суворо на нових даних тестової частини, які не використовувалися під час навчання.

Обґрунтування вибору метрик:

Оскільки в наборі спостерігається виражений дисбаланс класів (82.3% до 17.7%), традиційна метрика Accuracy є оманливою (константний прогноз нулів уже дає 82.3% точності, не маючи жодної практичної цінності). Головними критеріями оцінки обрано ROC-AUC (показник здатності моделі ранжувати ймовірність затримки) та F1-Score (гармонійне середнє точності й повноти для міноритарного класу).

Опис моделей:

1. Просте рішення (Baseline): DummyClassifier зі стратегією most_frequent, що константно передбачає нульовий клас («вчасно»).
2. Модель 1: Logistic Regression зі стандартизацією ознак (StandardScaler) як інтерпретовний лінійний бенчмарк.
3. Модель 2: LightGBM Classifier – оптимізований градієнтний бустинг над деревами рішень, розроблений для ефективної роботи на мільйонних вибірках даних із підтримкою паралельних обчислень.

4. Результати

Усі три рішення було протестовано на ідентичній вибірці з 1 142 802 рядків. Підсумкові показники наведено у таблиці:

Модель	Час навчання	Accuracy	F1-Score	ROC-AUC
Baseline (Most Frequent)	0.19 с	0.8230	0.0000	0.5000
Logistic Regression	1.58 с	0.8230	0.0000	0.6366
LightGBM Classifier	22.04 с	0.8235	0.0148	0.6916

Аналіз результатів:

- Базове рішення не виявляє жодного випадку затримки, демонструючи ROC-AUC = 0.5000 (еквівалент випадкового вгадування).
- Логістична регресія досягла показника ROC-AUC = 0.6366 за 1.58 секунди навчання, підтвердивши наявність статистично значущого лінійного зв'язку між часом, перевізником і затримкою.

- Градієнтний бустинг LightGBM показав найвищу якість із результатом ROC-AUC = 0.6916, успішно обробивши нелінійні залежності та взаємодії ознак на повному масиві спостережень усього за 22 секунди.

Головні чинники впливу на прогноз: Найбільшу вагу у прийнятті рішень моделлю мають: запланована година доби (dep_hour), код авіакомпанії (AIRLINE), аеропорт відправлення (ORIGIN_AIRPORT) та дистанція перельоту (DISTANCE).

5. Використання ШІ-асистентів

Під час виконання проєкту використовувався ШІ-асистент для наступних завдань:

1. Допомога у формулюванні архітектури скриптів та синтаксису оптимізації типів даних (downcasting типів у pandas та генерація ознаки dep_hour).
2. Складання шаблонів візуалізації графіків за допомогою бібліотек seaborn та matplotlib.
3. Допомога у структуруванні та редагуванні тексту звіту відповідно до вимог технічної документації курсу.

Увесь згенерований код було самостійно перевірено, виконано на власній локальній системі у середовищі VS Code та детально розібрано.

6. Висновки

Відповідь на питання дослідження: Так, затримку вильоту авіарейсу можна статистично передбачити за попередніми даними розкладу, досягнувши показника ROC-AUC = 0.6916 за допомогою алгоритму LightGBM. Це свідчить про наявність вираженого системного сигналу в розкладі перевезень.

Головні висновки:

1. Час вильоту є вирішальним фактором: ризик затримки зростає майже у 5 разів від ранкових рейсів (5:00) до вечірніх (20:00) через кумулятивний ефект пізнього прибуття попередніх бортів.
2. Сучасні інструменти обробки Big Data (формат Parquet, фреймворки Polars та LightGBM) дозволяють проводити повний цикл аналізу та навчання на вибірці з понад 5.7 млн рядків на звичайному персональному комп'ютері за лічені секунди

без використання дорогих хмарних кластерів.

Обмеження результату (де не варто застосовувати): Модель побудована виключно на характеристиках статичного розкладу і не враховує динамічні фактори реального часу: поточні метеорологічні умови (шторми, туман, ожеледиця), технічні несправності конкретних бортів та страйки персоналу. Відтак, модель не призначена для використання безпосередньо перед вильотом як оперативний тактичний інструмент.

Що можна зробити далі:

1. Об'єднати набір через API з історичними метеорологічними даними NOAA у розрізі аеропортів та дат.
2. Додати ознаку номера хвоста літака (TAIL_NUMBER) для відстеження ланцюга рейсів конкретного борту протягом дня.
3. Використати калібрування ймовірностей (Probability Calibration) для оптимізації порогу бізнес-рішень.

Список використаних джерел

1. 2015 Flight Delays and Cancellations. Bureau of Transportation Statistics, U.S. DOT. Kaggle Dataset. URL: https://www.kaggle.com/datasets/usdot/flight-delays
2. LightGBM Documentation: A highly efficient gradient boosting framework. URL: https://lightgbm.readthedocs.io/
3. Apache Arrow and Parquet Documentation: Columnar in-memory analytics. URL: https://arrow.apache.org/
4. Polars: Blazingly fast DataFrames in Rust & Python. URL: https://pola.rs/
5. Scikit-learn: Machine Learning in Python. URL: https://scikit-learn.org/